# Géopolitique de l'IA et enjeux de souveraineté

Regard d'un tech sur ces enjeux, pour d'autres tech

Paul Chevalier · CTO · Socratiz

Le Commit 2026 · exFabrica · The Camp · 24 septembre 2026

socratiz
FROM STRATEGY TO IMPACT

# Dix-neuf jours

**Le 12 juin 2026, un matin, Fable 5 ne répondait plus. Nulle part.**

**9 juin**
Publication de Claude Fable 5, avec Mythos 5.

**12 juin**
Contrôles à l'export du gouvernement américain : suspension mondiale.

**30 juin**
Levée des contrôles.

**1er juillet**
Rétablissement du service.

Claude Code

Cursor

Gateway

Cloud UE

**19**
jours

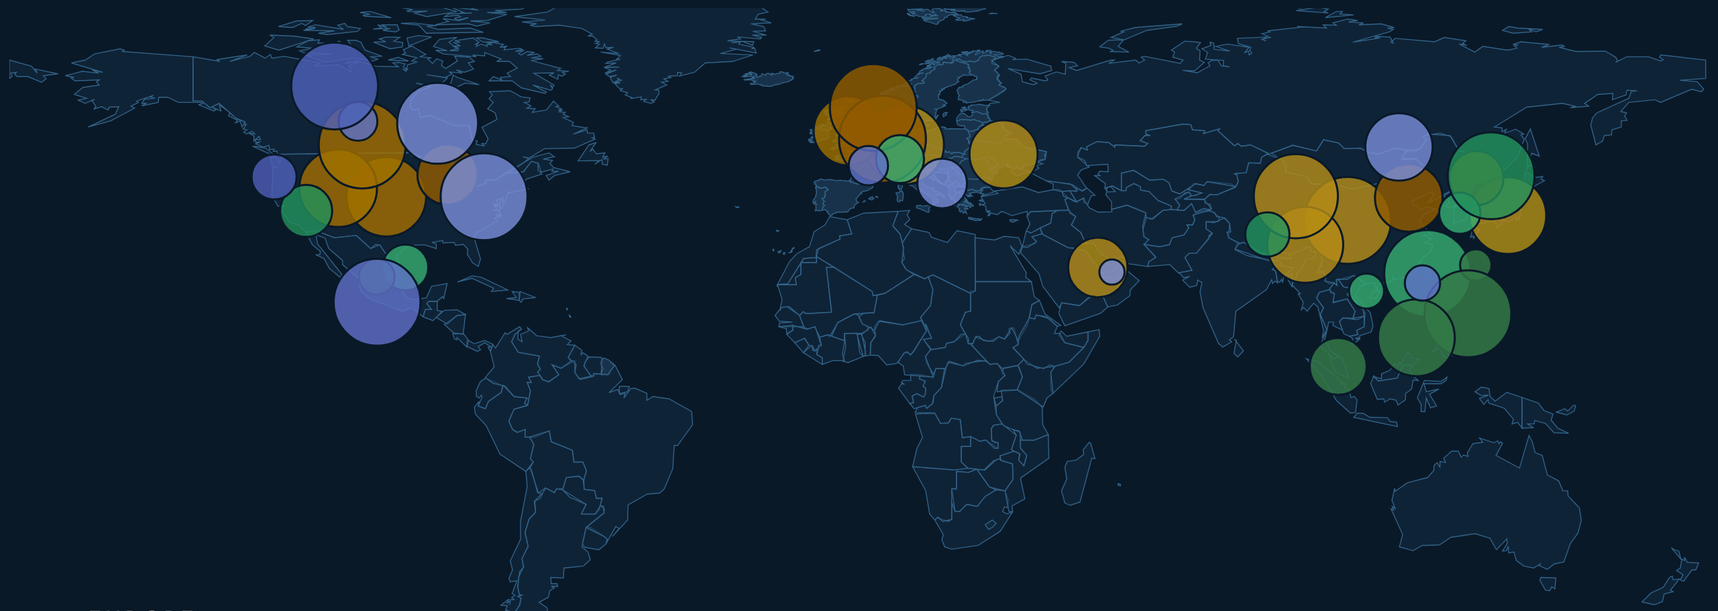
# Un zoom en cinq tableaux

**On part de la planète et on descend jusqu'à votre clavier. À chaque niveau, une question — et la recherche d'une prise.**

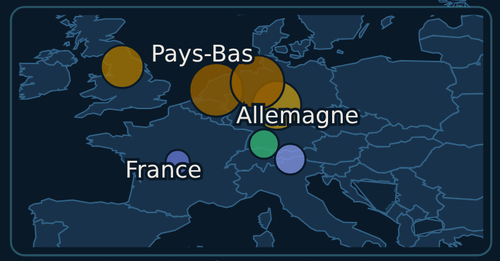
| | | |
|---|---|---|
| 1 | **Le monde** | Regard sur la chaîne d'approvisionnement, et qui maîtrise quoi |
| 2 | **Le matériel** | Acteurs du marché, et alternatives |
| 3 | **Le cloud** | Que promet-on vraiment ? |
| 4 | **Le harness** | Que pouvons-nous faire à notre échelle ? |
| 5 | **La personne** | Qu'est-ce que je garde chez moi ? |

# 01 La chaîne de valeur de l'IA dans le monde

**Des grappes, pas un réseau. À chaque étage, un ou deux pays tiennent l'essentiel.**



EUROPE




L'amont y est présent — l'aval, presque pas.

AMONT
- Ressources & gaz
- Conception & EDA
- Équipements

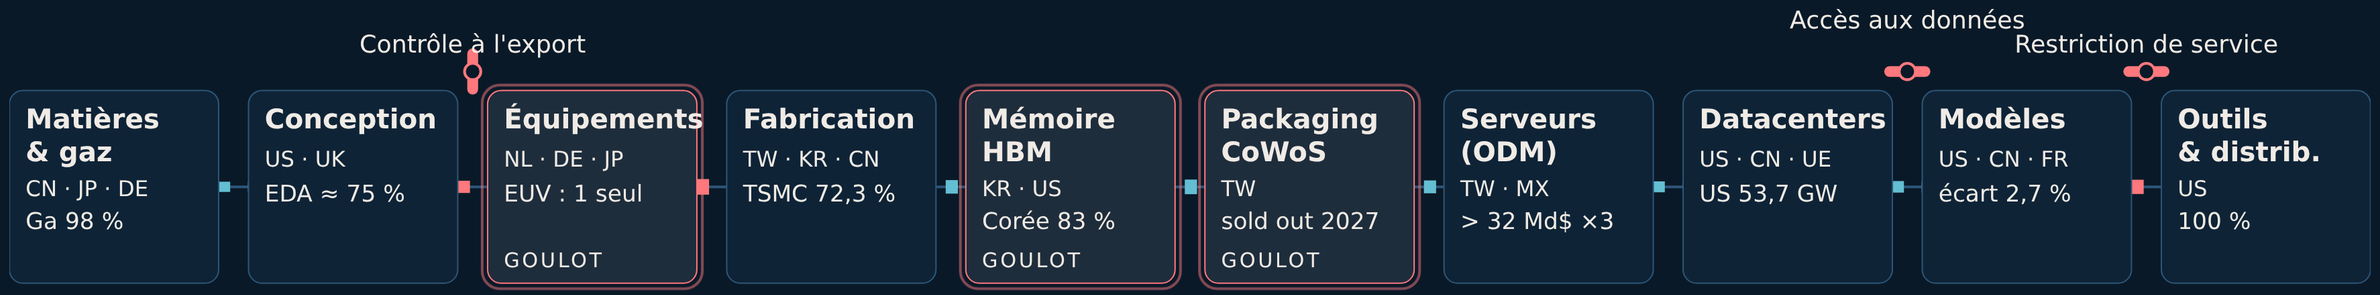
MILIEU
- Fabrication
- Mémoire HBM
- Packaging & serveurs

AVAL
- Datacenters & cloud
- Modèles
- Outils & distribution

Le rayon n'est comparable qu'au sein d'un étage.

# 01 La même chose en flux : la supply chain de l'IA

**Ce qui compte dans une chaîne, ce sont les maillons qu'on ne peut pas remplacer. Il y en a trois.**




## Contrôle à l'export

Sur les équipements, les puces, les modèles. **C'est ce qui vous a coupé Fable 5.**

## Accès aux données

CLOUD Act, FISA 702. Sur les datacenters, le cloud, les modèles.

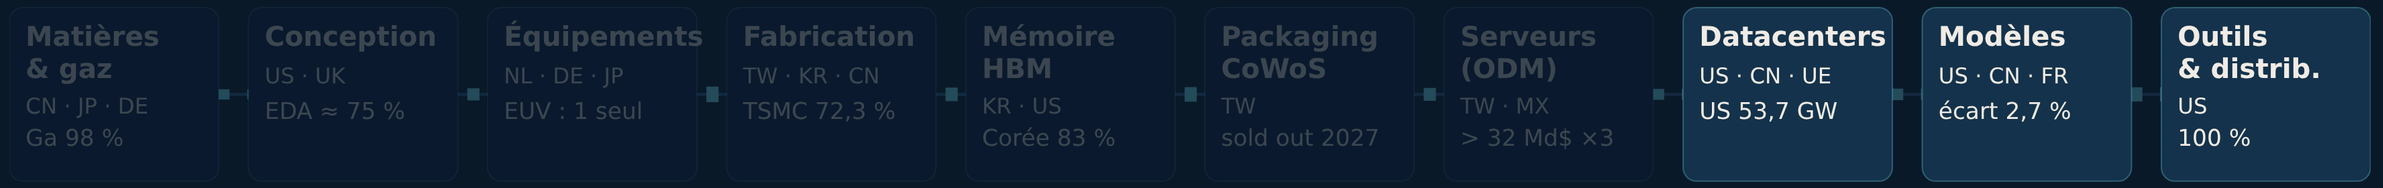
## Restriction de service

CGU, sanctions. Sur les modèles et les outils.

**La localisation de vos données n'agit que sur le deuxième.**

# 01 Remontons le fil depuis votre terminal (1/3) — l'aval

**L'outil, le modèle, le cloud. C'est là que vous êtes, et c'est là qu'il y a des prises.**




## Cloud & datacenters

Trois hyperscalers américains = **63 à 67 %** du monde, **70 %** de l'Europe.

Les Européens plafonnent à **15 %** de leur propre marché depuis 2022 — 29 % en 2017.

Levier : accès aux données (CLOUD Act, FISA 702), réquisition.

## Modèles

**Frontier fermé** : États-Unis. **Frontier ouvert** : Chine — DeepSeek V4, Qwen 3.x, Kimi K3, GLM-5.x. **2,7 %** d'écart de performance, avec 23 fois moins d'investissement privé.

**Europe** : Mistral, seul labo de premier plan.

Levier : contrôle à l'export. Hypothèse de renversement : si la Chine prend l'avantage, publie-t-elle encore ?

## Outils & distribution

La couche outil est américaine à **100 %** : Cursor (ARR > 2 Md$), Claude Code, Copilot (4,7 M d'abonnés payants), Codex.

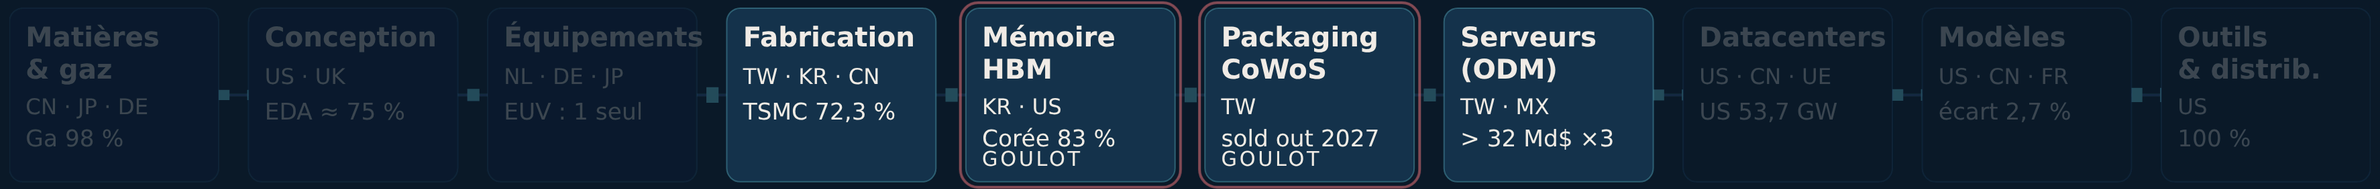
Hugging Face, la plateforme « neutre » des modèles ouverts, passe sous le contrôle du fournisseur dominant de GPU — **Nvidia, 12,93 Md$, 3 septembre 2026**.

Levier : restriction de service, CGU.

**Sur ces trois étages, il y a des prises pour nous : c'est le sujet des tableaux 3 et 4.**

# 01 Remontons le fil (2/3) — serveurs, puces, mémoire, packaging

**La couche la plus concentrée, et la moins accessible à une décision logicielle.**




## Serveurs

Foxconn, Quanta, Wistron (Taïwan), **> 32 Md$** chacun en 2025. Assemblage au Mexique et au Texas, sous pression tarifaire.

Nvidia livre désormais des *compute trays* pré-assemblés ≈ **90 % de la valeur** du système.

## Puces IA

Nvidia ≈ **70 à 80 %** de la valeur des accélérateurs. **89 Md$** de datacenter en un seul trimestre.

ASIC captifs — TPU, Trainium, Maia, MTIA — **27,8 %** des livraisons.

Huawei prend le marché chinois par défaut : Nvidia de 95 % à ~55 % en un an.

## Mémoire HBM

Corée **83 %**. Micron 18 %.

C'est le composant qui coûte cher dans un H200, et c'est le goulot de Huawei.

## Packaging

CoWoS ≈ **1 M de wafers** en 2026 : Nvidia 60 %, Broadcom 15 %, AMD 11 %.

**Sold out** jusqu'en 2027.

**Prise pour nous : aucune à court terme.** **Cette couche se couvre par des stocks, des contrats et de la diversification d'achat — pas par une ligne de configuration.**

# 01 Remontons le fil (3/3) — fonderie, lithographie, matières

**Tout en amont, la géographie se retourne : l'Europe a ses meilleures cartes, la Chine a ses leviers.**

**Matières & gaz**
CN · JP · DE
Ga 98 %

**Conception**
US · UK
EDA ≈ 75 %

**Équipements**
NL · DE · JP
EUV : 1 seul
GOULOT

**Fabrication**
TW · KR · CN
TSMC 72,3 %

**Mémoire HBM**
KR · US
Corée 83 %

**Packaging CoWoS**
TW
sold out 2027

**Serveurs (ODM)**
TW · MX
> 32 Md$ ×3

**Datacenters**
US · CN · UE
US 53,7 GW

**Modèles**
US · CN · FR
écart 2,7 %

**Outils & distrib.**
US
100 %

## Fonderie

TSMC **72,3 %** (T1 2026), onze fois Samsung. « ~90 % des puces IA de pointe ».

Intel 18A en volume depuis janvier 2026, **État américain actionnaire à 9,9 %**. SMIC bloqué au 5 nm-class à faible rendement.

Rapidus (Japon) 2 nm en 2027 ; ESMC Dresde en 2027, sur du 28-12 nm.

## Lithographie & équipements

ASML : 32,7 Md€, 535 systèmes en 2025, **monopole EUV** avec Zeiss et Trumpf.

La Chine reste son premier marché acheteur — 49,3 Md$ d'équipements en 2025 — mais à 14 % des ventes ASML au T2 2026. Projet américain « MATCH Act » pour bloquer même le DUV.

Nexperia, octobre-novembre 2025 : l'automobile européenne « à quelques jours de l'arrêt ».

## Matières & gaz

**Chine** : gallium 98 %, germanium 68 %, tungstène ≈ 80 %, raffinage des terres rares 90 %.

**Japon** : photorésines > 70 %, résines EUV > 95 %.

**Hélium** : le Qatar, un tiers du monde, frappé en mars 2026 — prix spot doublé. **Néon** : Ukraine ≈ 50 % avant 2022.

**Embargo chinois suspendu — jusqu'au 27 novembre 2026.** C'est dans deux mois.

# 01 L'entreprise n'a pas vocation à être souveraine

**La bascule conceptuelle : abandonner un mot d'État pour une grandeur qui se mesure.**

## Souveraineté

« Le pouvoir suprême d'un État sur son territoire, qui ne reconnaît aucune autorité supérieure. » Bodin, XVI$^{e}$ siècle.

- Une entreprise n'a pas de territoire, n'édicte pas de loi, et relève de la juridiction de son siège *et* de celles de ses fournisseurs.
- Pour l'inférence LLM, la souveraineté au sens strict **n'existe pas** : le matériel est conçu aux États-Unis et fabriqué à Taïwan, quels que soient le modèle et le lieu d'exécution.

mot d'État

## Autonomie stratégique

« La capacité de décider et d'agir sans dépendre d'un tiers. »

Réduire, couche par couche, son exposition aux décisions qu'on ne contrôle pas — coupure, prix, CGU, réquisition — et conserver une capacité de continuité et de négociation.

## Et ça se mesure.

Part du trafic par fournisseur —

Temps de bascule testé —

Part du sensible en périmètre maîtrisé —

Règle de lecture pour la suite : « cloud souverain », « inférence souveraine » signifient *dans un périmètre maîtrisé* ou *sous juridiction européenne* — jamais au sens propre.

# 02 Le paysage des accélérateurs

**Deuxième tableau. Trois familles, et une question : y a-t-il une concurrence ?**



## GPU marchands

**Nvidia** — Blackwell → Blackwell Ultra GB300 → Vera Rubin, en production depuis mars 2026

**AMD** — MI300X → MI350/MI355X → MI400 « Altair » / MI455X et rack Helios, volume T3-T4 2026

**Intel** — Gaudi 3, Arc Pro B60/B50, Crescent Island annoncé pour 2026-27

louable chez n'importe qui

## ASIC captifs

**Google** TPU v7 Ironwood · **AWS** Trainium 2/3 · **Microsoft** Maia 200 · **Meta** MTIA · **Huawei** Ascend 910C / 950 (Chine)

Non louables ailleurs que chez leur propriétaire.

louable chez un seul

## Architectures alternatives

**Cerebras** WSE-3 — wafer-scale, 44 Go de SRAM, 900 000 cœurs

**Groq** LPU — licence et équipe absorbées par Nvidia, décembre 2025, ~20 Md$ ⚠

SambaNova, Etched, Tenstorrent, d-Matrix

**Europe** : SiPearl Rhea1, Vsora Jotunn-8, Axelera

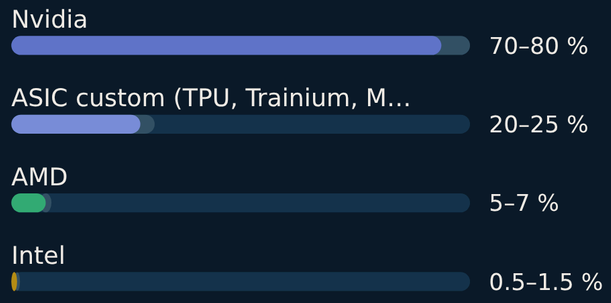
en volume : 0 en Europe

# 02 À qui appartient le calcul ?

## Trois façons de compter, trois réponses. La réponse dépend de ce qu'on mesure.

### Valeur des accélérateurs IA, monde

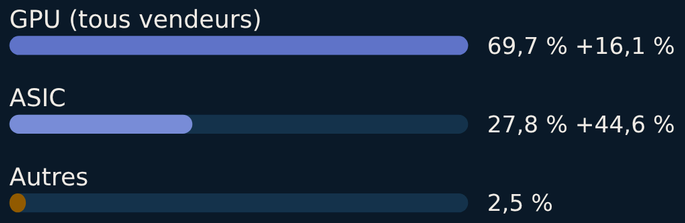
% de la valeur · 2026




TrendForce via TechTimes, 26 mai 2026

### Livraisons de serveurs IA, par type de puce

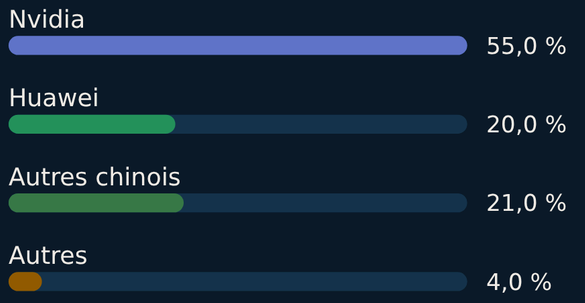
% des livraisons · 2026




TrendForce, 20 janv. 2026

### Chine : accélérateurs IA, en unités

% des ~2,2 M d'unités · 2025




IDC via Medium, avr. 2026 ⚠ source secondaire

2024 : Nvidia 95 %

GPU desktop (AIB), 12,5 M d'unités : Nvidia ~90 % · AMD ~8 % · Intel ~2 % — T2 2026

# 02 Forces et faiblesses : quatre fiches

**La variable d'ajustement du minutage : quarante secondes si l'on est en retard, une phrase par acteur.**

## Nvidia

**Position** — quasi-monopole du GPU marchand. 193,7 Md$ de datacenter sur l'exercice clos en janvier 2026, **89 Md$** au seul T2 FY2027. Guidance sans aucun revenu Chine.

**Force** — *le fossé s'est déplacé de la bibliothèque au rack* : NVLink rack-scale, 900 Go/s par GPU en NVL72 contre 50-100 Go/s entre nœuds.

**Faiblesse** — 6 à 6,5 M$ le rack GB300 NVL72 ; même dépendance que tout le monde à TSMC, CoWoS et HBM ; exposition politique.

Neutralisation des rivaux par le capital : Intel 5 Md$, Groq, Hugging Face 12,9 Md$.

## AMD

**Position** — le challenger devenu crédible. Datacenter 6,7 Md$ au T2 (+107 %). Contrats OpenAI et Meta, 6 GW chacun, sur MI450.

**Force** — mémoire (MI455X : 432 Go HBM4), pilotes ouverts.

**Faiblesse** — ROCm. « Inutilisable out-of-the-box » en décembre 2024 ; bugs « moins fréquents de plusieurs ordres de grandeur » en octobre 2025 ; « écrasé » en FP4 en février 2026.

`amdgpu → RADV · ~~AMDVLK~~ · AMDGPU-PRO · ROCm/HIP · ROCm-OpenCL`

Un pilote noyau, quatre userspaces, dont un abandonné.

## Intel

**Position** — hors du GPU datacenter jusqu'en 2027. Falcon Shores annulé, Crescent Island en sampling H2 2026.

**Force** — des niches réelles : Arc Pro B60 (24 Go, ~500 $) et Project Battlematrix (192 Go) pour l'inférence locale ; encodage vidéo ; inférence CPU (AMX, OpenVINO) ; fonderie 18A en volume.

**Faiblesse** — pas de HBM soudée en vue, oneAPI marginal, ~1 % du marché.

## Cerebras

**Position** — la puce de la taille d'un wafer : 900 000 cœurs, 44 Go de SRAM, plus de 1 100 tokens/s. IPO Nasdaq mai 2026, ~50 Md$.

**Force** — latence et débit par flux.

**Faiblesse** — dépendance client extrême : 86 % du CA chez deux clients en 2025, désormais OpenAI pour 20 des 25,4 Md$ de backlog. Petite mémoire par puce, pile propriétaire, prix.

# 02 Y a-t-il une vraie concurrence ? Et ce que ça change pour vous

**La seule chose de tout ce tableau qui descend jusqu'à votre docker run : la mémoire.**

### Entraînement frontier

**Non.**

Quasi-monopole Nvidia.

### Inférence

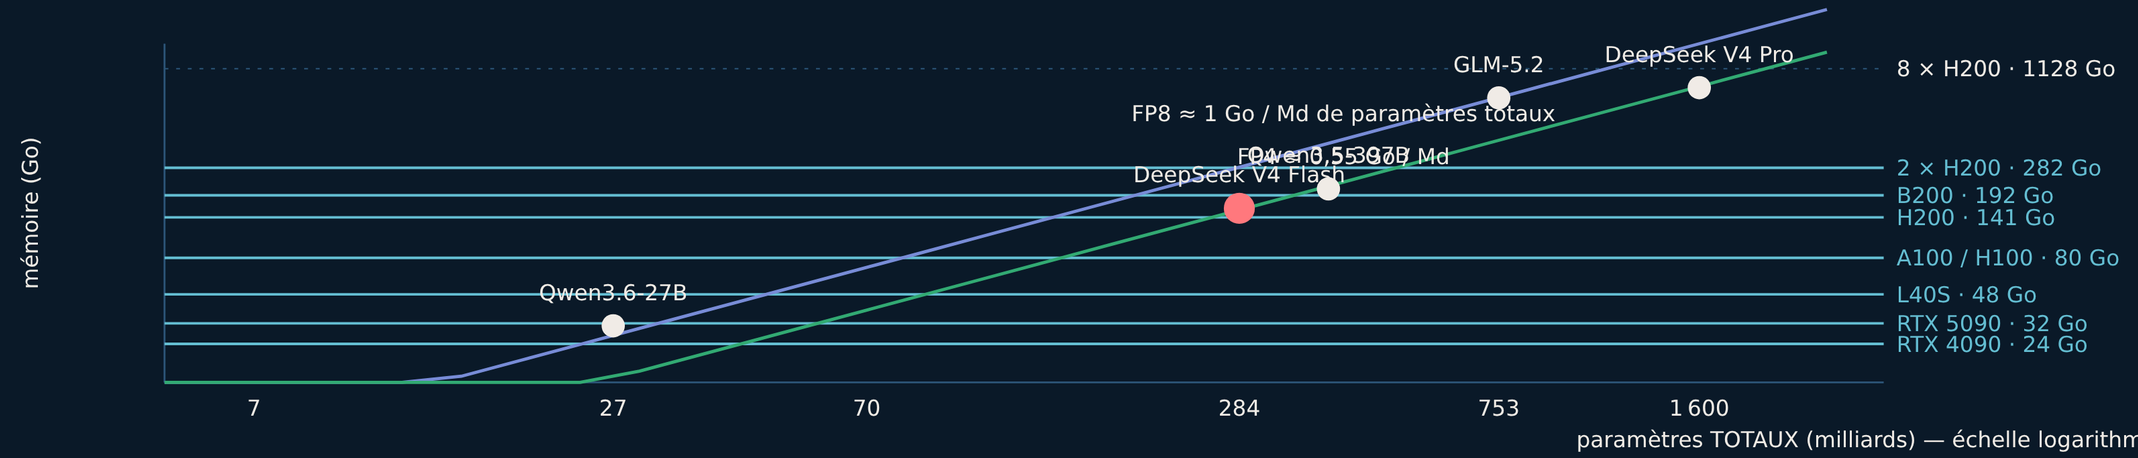
**Un oligopole se forme.**

ASIC captifs, AMD en volume fin 2026. La portabilité coûte « 2 à 6 semaines ».

### Europe

**Zéro.**

Aucun accélérateur datacenter en volume.




Le modèle doit tenir **entièrement** en mémoire GPU.

La mémoire suit le nombre **total** de paramètres, pas les actifs d'un MoE.

FP8 ≈ 1 Go par milliard, FP4 ≈ 0,55. **L'artefact publié fait foi.**

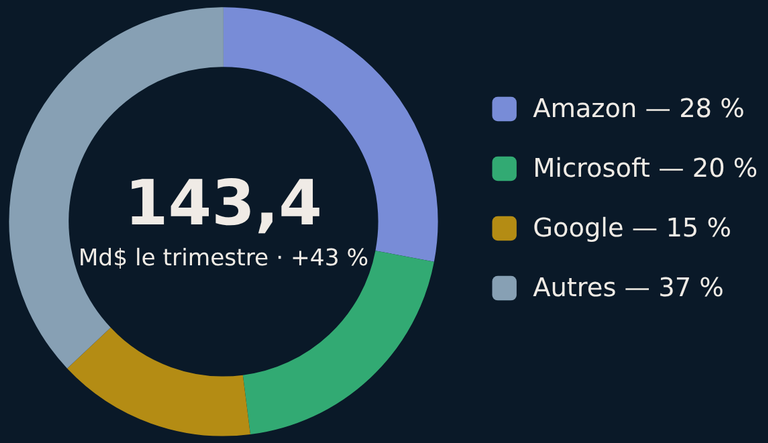
24, 32, 48, 80, 141, 192 Go — **il n'existe pas de demi-carte**.

Le vrai tueur du matériel modeste, c'est le **prefill** : 1 à 2 s sur 8 × H200, ≈ 1 min sur une station à mémoire unifiée. « On achète de la mémoire, pas des utilisateurs. »

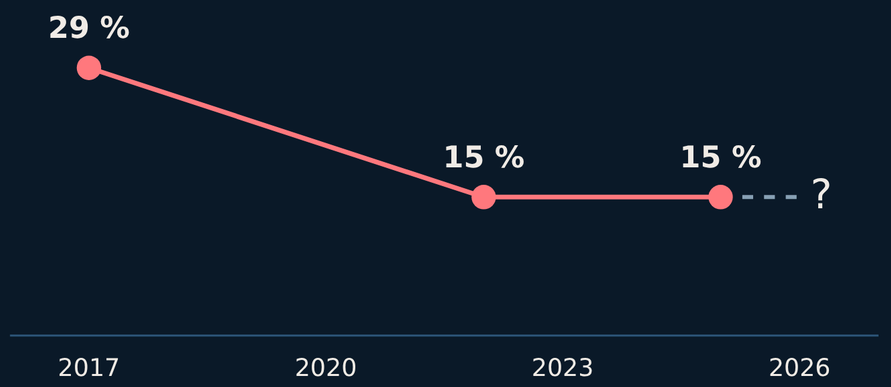
# 03 Qui héberge l'Europe

**Le marché croît de 35 % par an. Les Européens croissent avec lui, et ne rattrapent rien.**

**Cloud mondial · T2 2026**




**Part des fournisseurs européens dans le cloud européen**




**AWS + Microsoft + Google = 70 % de l'Europe**

# 03 Sept garanties qu'on confond

Relevé septembre 2026 — périssable

## Proposition de grille de lecture, à construire et à affiner.

| | **API directe**<br>Anthropic, OpenAI | **Hyperscaler**<br>Bedrock, Vertex, Azure | **Open-weight géré**<br>Scaleway, OVHcloud, IONOS | **Éditeur européen**<br>Mistral La Plateforme | **On-premise**<br>vos GPU, vLLM |
|---|---|---|---|---|---|
| 1 · Résidence des données au repos | × non | ✓ acquis | ✓ acquis | ✓ acquis | ✓ acquis |
| 2 · Localisation du traitement | × non | ✓ acquis | ✓ acquis | ✓ acquis | ✓ acquis |
| 3 · Rétention (ZDR) | ~ condition | ~ condition | ✓ acquis | ~ condition | ~ condition |
| 4 · Qui voit le contenu | × non | ~ condition | ✓ acquis | × non | ✓ acquis |
| 5 · Juridiction | × non | × non | ~ condition | ✓ acquis | ✓ acquis |
| 6 · Qualification SecNumCloud | × non | × non | × non | × non | ? à vérifier |
| 7 · AI Act | ? à vérifier | ? à vérifier | ? à vérifier | ? à vérifier | ? à vérifier |

↑ La confusion la plus fréquente : on répond sur les lignes 1 et 2, on ne dit rien de la ligne 5.

**Anthropic direct** — pas de région d'inférence « eu ». Le ZDR n'existe pas sur les « Covered Models » : Fable 5 / 5.1 et Mythos imposent 30 jours.

**Microsoft Foundry**, modèles partenaires — Anthropic est *independent data processor* : le laboratoire voit le contenu. Ce n'est pas le cas chez Vertex ni Bedrock.

**Mistral La Plateforme** — hébergement UE par défaut, **mais** entraînement sur vos données par défaut sauf opt-out, et ZDR « at our discretion ».

**La localisation règle une question — où se trouvent physiquement les données et le calcul — et n'en règle aucune autre par elle-même.**

# 03 « Pouvez-vous garantir que les données de citoyens français ne seront jamais transmises aux autorités américaines sans l'accord des autorités françaises ? »

**Commission d'enquête du Sénat sur la commande publique, 10 juin 2025.**

> Non, je ne peux pas le garantir,
> mais, encore une fois, cela ne s'est
> encore jamais produit.

Anton Carniaux, Microsoft France, devant le Sénat — 10 juin 2025

| | | |
|---|---|---|
| **Rétention** | ZDR / détection d'abus modifiée — par défaut chez Bedrock et les Européens, sur approbation… | ✕ localisation |
| **Accès du fournisseur du modèle** | Choisir une voie où il n'est pas sous-traitant : Vertex, Bedrock, Azure OpenAI. Éviter Foun… | ✕ localisation |
| **Réquisition (CLOUD Act, FISA 702)** | Changer de chaîne de contrôle, pas de région. | ✕ localisation |
| **Transferts RGPD** | Localisation UE ET entité contractante dans l'EEE. | ✓ localisation |
| **Qualification SecNumCloud** | Aucun LLM-as-a-service qualifié à ce jour. S3NS : open source seulement, Gemini exclu. | ✕ localisation |
| **Indisponibilité physique** | Multi-zone, multi-région chez le même opérateur. | ✓ localisation |

**La localisation est la bonne réponse à deux risques sur six.** Et elle n'améliore pas la sécurité technique : un endpoint européen d'un hyperscaler a exactement les mêmes propriétés que son endpoint américain. C'est le même service.

# 03 Les Européens : ce qu'ils offrent vraiment

## Meilleure que ce qu'on en dit, et moins bonne que ce qu'elle promet.

| ACTEUR | LLM-AS-A-SERVICE | CE QUI EST ACQUIS | CE QUI MANQUE |
|---|---|---|---|
| **Scaleway** FR | Generative APIs : GLM-5.2, DeepSeek-V4-Flash, Qwen, Mistral, Llama 3.3-70B, Whisper. Ex. DeepSeek-V4-Flash à 0,40 / 0,80 €/M tokens. | Paris uniquement, ZDR par défaut, prix compétitifs | Pas SecNumCloud ; chaîne de contrôle à confirmer |
| **OVHcloud** FR | AI Endpoints : une vingtaine de modèles (gpt-oss, Qwen 3.x jusqu'à 397B, Llama, Whisper) | SecNumCloud 3.2 sur le Public Cloud IaaS (juin 2026), ZDR affirmé | Les AI Endpoints ne sont **pas** qualifiés |
| **IONOS · STACKIT · Infomaniak** DE · DE · CH | Catalogues open-weight : Qwen, Mistral, Gemma, Llama | C5 (Allemagne), « no third-party access » | Pas de frontier ; la Suisse est hors UE |
| **Mistral** FR | La Plateforme + Mistral Compute : GB300, 44 MW à Bruyères-le-Châtel, site suédois en 2027, 1 GW visé en 2030 | Seul éditeur frontier européen ; 3 Md€ levés le 8 septembre 2026 | DPA à lire : entraînement par défaut, ZDR discrétionnaire. Infrastructure sous-jacente non documentée |
| **Néoclouds** Nebius NL · Nscale UK · DT DE | GPU cloud et inférence. 10 000 Blackwell à Munich, février 2026 | Capacité réelle, en croissance | Clients principaux : Microsoft et Meta. Sesterce en redressement judiciaire le 5 février 2026 |

**Le différenciateur européen qui tient, en 2026, c'est modèle open-weight + ZDR contractuel + juridiction UE.**

Aucune API LLM managée n'est SecNumCloud. Aucun modèle fermé frontier n'est disponible dans une offre qualifiée. **Pas un drapeau : une combinaison.**

# 03 TEE : quand l'hébergeur ne peut plus lire

**La seule technologie de ce tableau qui vous donne une prise directe. Et ce qu'elle ne garantit pas.**




## Ce que ça garantit

- L'hébergeur distant ne lit ni prompts, ni sorties, ni poids.
- Le code exécuté est bien celui qui a été mesuré.
- Coût : **1 à 3 %** de performance sur B200 bien configuré.

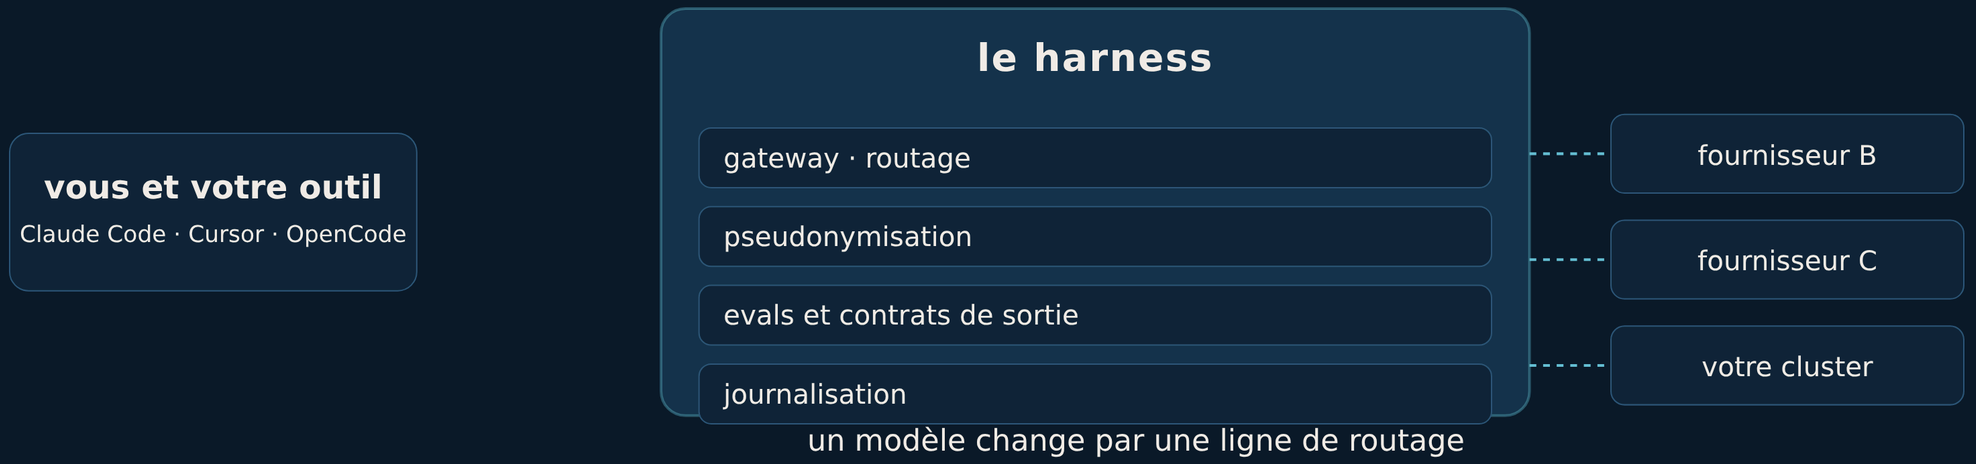
## Ce que ça ne garantit pas

- **Rien contre l'opérateur de l'enclave.** L'attestation prouve « c'est bien son code », pas « son code ne journalise pas ».
- **Rien contre l'accès physique.** TEE.fail, moins de 1 000 $ ; DDRop, moins de 200 $.
- **La racine de confiance reste Intel, AMD, Nvidia.**

**Qui le fait en 2026 :** Azure · Google Confidential Space · AWS *sans GPU* · Apple Private Cloud Compute · Meta pour WhatsApp · Cohere Model Vault · Edgeless Systems, qui sécurise le dossier médical de 50 millions d'Allemands. Aucun laboratoire frontier n'offre d'inférence attestable par le client.

# 04 Le harness est l'actif, l'intelligence est louée

**Tout ce qu'on a vu jusqu'ici, vous ne le contrôlez pas. Voici ce que vous contrôlez.**




### Agnostique

Au modèle **et** au fournisseur.

### Confidentialité réglable

Par projet, pas globalement.

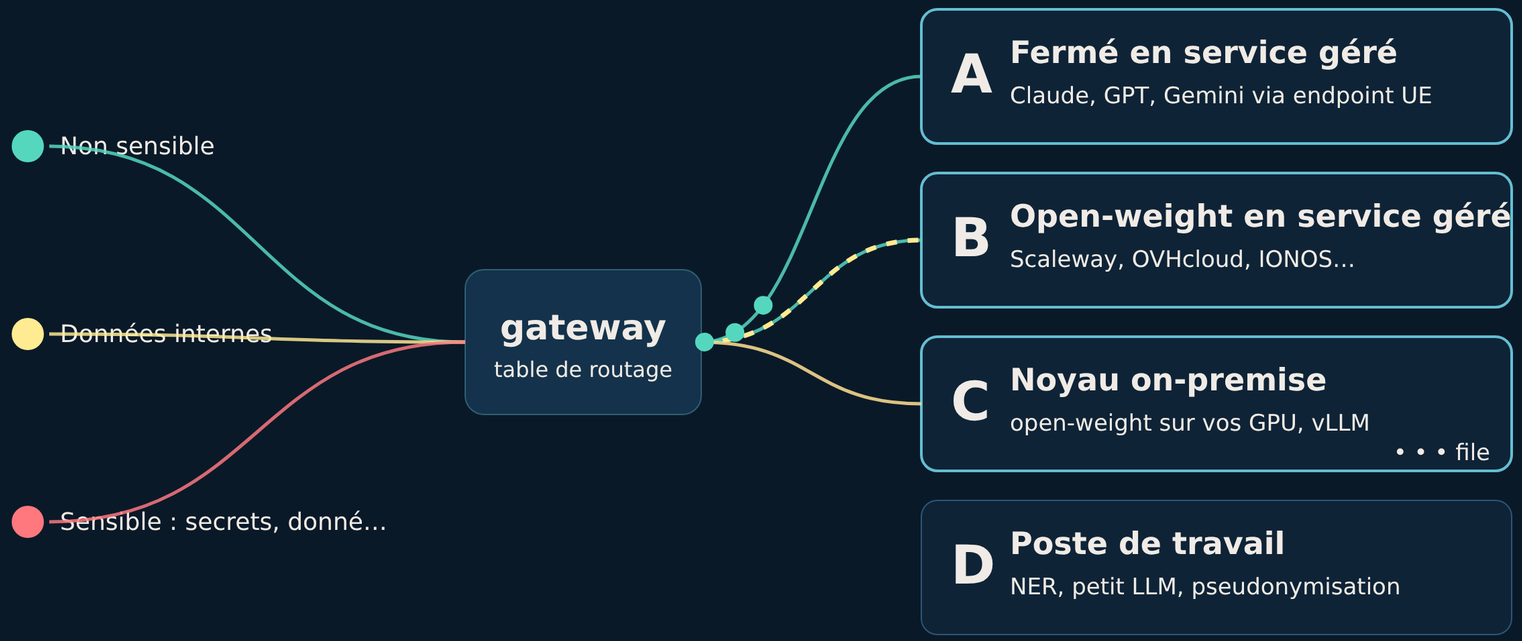
### Repli maintenu au chaud

Une option jamais exercée est une option morte.

**Le harness est l'actif. L'intelligence est louée.**

# 04 Étager l'inférence par niveau de confidentialité

**Vos prompts n'ont pas tous la même sensibilité : ils n'ont pas tous besoin du même fournisseur.**




## Les règles

- Aucun poste ne sait où s'exécute l'inférence.
- Notre propre cluster est un fournisseur comme un autre dans la table de routage.
- **Le sensible attend, le non-sensible déborde.**

Part du sensible dans un périmètre maîtrisé 82 %

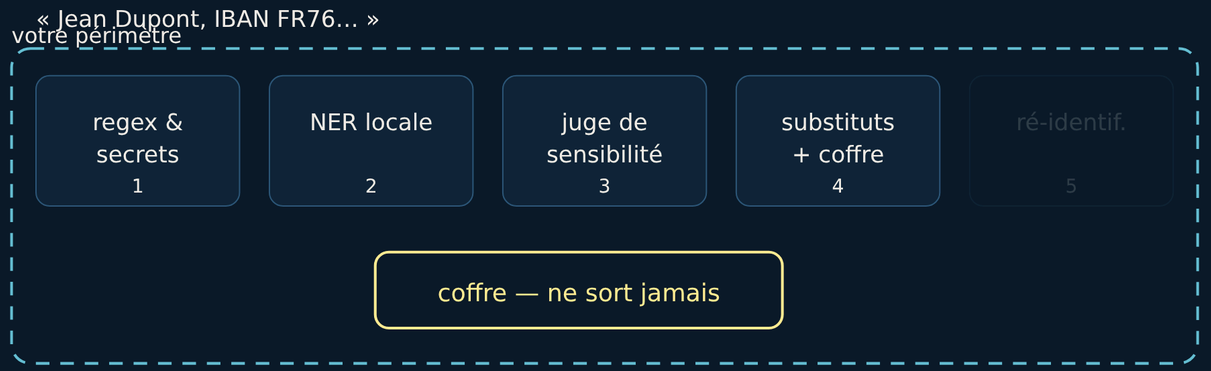
C'est le troisième indicateur de la slide 9 qui se remplit.

# 04 Le principe Manhattan, et la pseudonymisation avant la sortie

## Deux idées d'architecture qui relèvent de la confidentialité par conception.




**Aucune ne s'assemble chez un seul.**




### Le corollaire

Multiplier les modèles devient une mesure de **confidentialité**, plus seulement de performance.

Tension assumée : cloisonner, c'est appauvrir délibérément le contexte. Un curseur par projet, pas un dogme.

### Pour le code

Détection de secrets toujours ; pseudonymiser les **données**, pas le code ; **router** le code intrinsèquement sensible.

« Le code d'un moteur de pricing l'est par sa logique, pas par les valeurs qu'il contient. »

### Deux avertissements

« PRIX_1 et PRIX_2 » empêche de calculer l'écart. Et sans mesure adverse de ré-identification, **c'est un théâtre de sécurité**.

Une donnée envoyée avant détection ne se retire plus.

# 04 Open-weight : téléchargeable ne signifie pas exploitable

## Ce que ça change

Un modèle **détenu et exploitable** réduit fortement la dépendance au service de l'éditeur. *Un modèle figé ne se dégrade pas.*

« La copie locale des poids passe de commodité à **actif rare**, au même titre qu'un stock stratégique. »

Chine : DeepSeek V4 Pro 1,6 T et V4 Flash (MIT), Kimi K3, GLM-5.2 (MIT), Qwen3.6-27B (Apache-2.0). USA : gpt-oss, Gemma 4, Llama 4, Olmo 3. Europe : Mistral Small 4, EuroLLM, Apertus 70B.

## Ce que ça ne change pas

« Détenu et exploitable » exige **trois conditions simultanées**.

Licences à lire pour *cette révision* : clause MaaS chez Kimi K3 ; **aucun droit au-dessus de 20 M$ de CA mensuel** chez Mistral Medium 3.5 et Devstral 2 ; non commercial chez MiniMax.

**« Les open weights n'éliminent pas le verrouillage ; ils le déplacent vers votre propre infrastructure. »**

## La discipline

Un **archivage redéployable** : poids + tokenizer + config + licence de la révision + image du moteur figée + empreintes. Restauration **testée chaque année**.

**« Poids publiés, licence lue, configuration qualifiée. »**

Précédents de retrait : LLaMA 1 (2023), dépôts SD 1.5 retirés par Runway (2024), GPT-2 ouvert → GPT-3 fermé.




**Les open weights n'éliminent pas le verrouillage : ils le déplacent chez vous.**

**Qwen3.5-397B** janvier 2026 — un nœud complet, 8 cartes, 76,4 % → **Qwen3.6-27B** avril 2026 — une carte de 48 Go, 77,2 %. **Ne planifiez pas sur une position, planifiez sur le mouvement.**

# 04 Une option jamais exercée est une option morte

## 1 · Portez du trafic réel

L'étage de repli sert en permanence une fraction du trafic — les projets les plus sensibles, typiquement.

Sinon on découvre ses bugs le jour de la crise.

## 2 · Exercez la bascule

Une fois par an au moins, sans dépendance au fournisseur qu'on simule indisponible — gateway, authentification et secrets compris.

« Un noyau local derrière une gateway hébergée chez l'opérateur en panne n'est pas un secours. »

## 3 · Jamais sur une personnalité

Contrats de sortie : schémas, tests, oracles. Alias de routage plutôt que versions épinglées.

GPT-4o : retiré le 8 août 2025, rétabli en 24 h, **retiré définitivement le 13 février 2026**.

## 4 · Des evals, pas des benchmarks

**Evals** : vérification que le système IA répond aux critères métier de qualité.

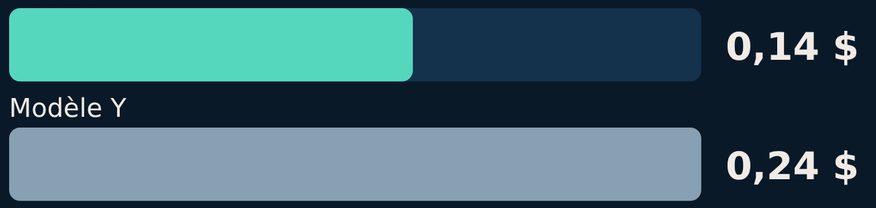
Unité de décision : le **coût complet par tâche réussie**.

**Prix par million de tokens de sortie**




gagnant : modèle Y

**Coût complet par tâche réussie**




gagnant : modèle X

**Le modèle cinq fois moins cher au token coûte ici 70 % de plus par tâche réussie.**

# 04 Agentic coding et agentic desktop plus autonomes : cinq gestes

## Du plus simple au plus structurant.

**1 Une gateway devant tous vos harness** LiteLLM ou équivalent — y compris pour les externes

Une seule clé locale, les clés amont portées par la gateway (zero credential), double surface d'API (OpenAI et Anthropic), FinOps par projet, cache de préfixes préservé, **table de routage versionnée en Git**. Un fournisseur change par une ligne.

**2 Un proxy local de pseudonymisation entre l'outil et la gateway** hooks Claude Code, plugin OpenCode, ou proxy HTTP transparent

Indépendant de l'outil. Détection de secrets bloquante, NER locale, coffre local. **Le poste devient l'étage D.**

**3 Un petit modèle local pour les tâches simples du harness** 4 à 30 Md de paramètres sur le NPU ou le GPU du poste

Classification de sensibilité, résumé, NER, complétion triviale. L'inférence locale est devenue une fonction standard du poste : Copilot+ PC à 40 TOPS, Apple Neural Engine, Ryzen AI, Core Ultra.

« **Ce qui peut être du code ne consomme pas d'intelligence** », et ce qui reste ne consomme pas forcément du frontier.

**4 Une sandbox et une journalisation des actions de l'agent** conteneur, moindre privilège, journal des tool calls, human-in-the-loop sur l'irréversible

L'absence de réseau sortant du moteur ne couvre pas les actions du système agentique : une sortie peut induire un appel d'outil, une requête externe, une écriture. **C'est la garantie que le fournisseur ne vous donnera jamais, parce qu'elle est chez vous.**

**5 Une couche de gouvernance qui appartient à l'entreprise, pas au laboratoire**

Les clients desktop des labs sont conçus pour vendre le modèle de leur éditeur. « Le poste de travail agentique se déploie sans gouvernance, comme le cloud en 2012. »

Ce que Socratiz explore : un agentic desktop open-core, LLM-agnostique, avec routage confidentialité × coût, cloisonnement Manhattan, pseudonymisation locale, sandbox, administration et FinOps centralisés. *« On ne concourt pas sur le modèle, on est la couche que l'entreprise possède. »* socratiz.fr ↗

# 05 Hygiène personnelle d'autonomie

**Le dernier niveau du zoom : ce que vous gardez chez vous, et les compétences que vous choisissez d'entretenir. Des habitudes, pas des règles.**



### Gardez votre contexte en texte, chez vous

Markdown, Git. Un dossier `about-me/`, vos conventions, vos décisions, vos prompts.

« Ce qui est coûteux à constituer, difficile à imiter et durable, c'est le contexte. »

### Jamais sur la personnalité d'un modèle

Des contrats de sortie, pas des habitudes de ton. Deux outils au moins, un modèle ouvert au moins.

Pour que la bascule soit un geste, pas un deuil.

### Le modèle le plus sobre qui passe le seuil

« Pas la plus intelligente : la moins chère qui passe le seuil. »

Et l'inverse : un appel au frontier au bon moment évite dix relances d'un modèle léger.

### Gardez la compétence de commande

« La compétence d'exécution devient optionnelle ; la compétence de commande devient obligatoire. »

**« Si je ne sais plus ce que je fais, j'arrête. »**

### Lisez les fichiers

La licence, le DPA, la fiche mémoire. Le réflexe « européen = confortable, chinois = risqué » ne survit pas à la lecture.

L'artefact publié prime sur la fiche marketing.

### Mesurez, et archivez

Vos evals, votre coût par tâche réussie, votre concentration par fournisseur.

Un modèle ouvert redéployable, licence incluse, **restauration testée**.

# 05 Ce qu'il faut retenir

### Part du trafic par fournisseur

la connaissez-vous ? mesurée

### Temps de bascule testé

l'avez-vous exercé ? exercé

### Part du sensible en périmètre maîtrisé

la mesurez-vous ? 82 %

### L'autonomie n'est pas un état, c'est une capacité entretenue

Réduire couche par couche son exposition aux décisions qu'on ne contrôle pas, et conserver une capacité de continuité et de négociation.

« Une option jamais exercée est une option morte. »

### Ce qui se mesure se pilote

Trois indicateurs suffisent, et ils ne dépendent d'aucun fournisseur. Le coût par tâche réussie, pas le prix au token.

« Le token est l'unité de la facture ; il ne doit jamais être l'unité de la décision. »

### On choisit son exposition, on ne l'annule pas

La localisation répond à deux risques sur six. Le TEE déplace la confiance. Les open weights déplacent le verrouillage.

Aucun de ces leviers ne supprime la dépendance — chacun la déplace vers un endroit que vous choisissez.

### Planifier sur le mouvement, pas sur une position

Les vannes s'ouvrent et se ferment en semaines — la prochaine échéance est le **27 novembre 2026**.

Et les exigences matérielles descendent aussi vite : **Qwen3.5-397B** (janvier 2026) demandait un nœud complet de 8 cartes pour 76,4 % à SWE-bench Verified ; **Qwen3.6-27B** (avril 2026) fait 77,2 % sur **une seule carte de 48 Go**. Scores auto-déclarés par l'éditeur ; relevés Hugging Face du 16 septembre 2026.

**Vous ne serez jamais souverains. Vous pouvez être autonomes, et le mesurer.**

# Questions

**Part du trafic par fournisseur**
Le savez-vous ?

**Temps de bascule testé**
L'avez-vous exercé ?

**Part du sensible en périmètre maîtrisé**
La mesurez-vous ?

Le dossier documentaire de ce support — glossaire, précédents, tableaux, sources — est disponible.
On reparle mémoire d'entreprise à la table ronde de **11 h 45**. le programme ↗

**Paul Chevalier** · CTO
Le Commit 2026 · exFabrica

# A Chronologie Fable 5 — juin-juillet 2026

| DATE | ÉVÉNEMENT |
|---|---|
| **9 juin** | Publication de Claude Fable 5, avec Mythos 5. |
| **12 juin** | Le gouvernement américain applique des contrôles à l'export imposant de restreindre l'accès aux ressortissants étrangers « aux États-Unis comme à l'étranger ». Faute de moyen fiable de vérifier la nationalité en temps réel, **suspension pour tous les clients, toutes plateformes** — API directe, Bedrock, Vertex, Foundry. |
| cause invoquée | Un rapport de chercheurs d'Amazon décrivant une méthode de contournement des garde-fous : demander au modèle de lire une base de code et d'y identifier des vulnérabilités. Anthropic conteste la proportion — « recalling a commercial model deployed to hundreds of millions of people » pour un contournement étroit. |
| **30 juin** | Levée des contrôles. |
| **1er juillet** | Rétablissement du service. |

## Ce qu'il faut en retenir

- La coupure vient de **la juridiction dont on dépend le plus**.
- Par un mécanisme **distinct de l'accès aux données**.
- **Indépendamment du contrat et de la région** choisie.
- « Une option de continuité doit exister *avant* l'événement. »

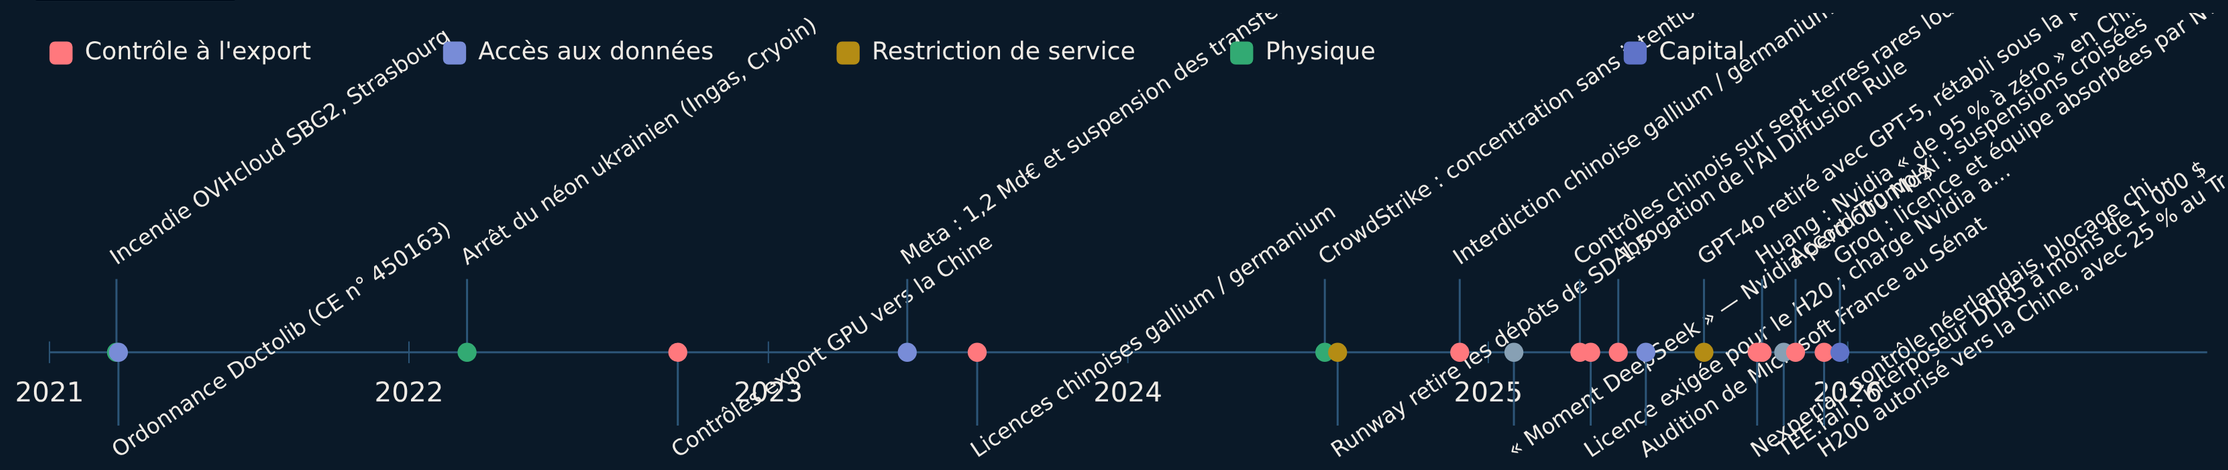
## Ce qu'il ne faut pas dire

**« Disparition ».**

Il est revenu. C'est précisément ce qui rend le précédent utilisable : ce n'était pas une catastrophe, c'était un incident de production de dix-neuf jours.

Sources publiques : le communiqué du 12 juin et le billet « Redeploying Claude Fable 5 ».

# A Les vannes qui ont bougé — 2021 à 2026



# A Glossaire

**Le détail de chaque entrée est dans le dossier documentaire — touche D.**

## Concepts

- Souveraineté vs **autonomie stratégique**
- Les trois couches : modèle · infrastructure d'inférence · matériel
- Les quatre étages **A** / **B** / **C** / **D**
- Principe Manhattan
- « Une option jamais exercée est une option morte »

## Droit et conformité

- **ZDR** et abuse monitoring
- **CLOUD Act** (18 U.S.C. § 2713) et **FISA 702**
- Schrems II, DPF, SCC
- SecNumCloud, C5, EUCS
- **AI Act** : GPAI, haut risque, Digital Omnibus

## Technique

- Open-weight vs **open source** (OSAID 1.0)
- TEE, enclave, **attestation** (RATS, RFC 9334), SGX/TDX, SEV-SNP, Nvidia CC mode
- NER, GLiNER, Presidio, **FPE FF1**
- Gateway, LiteLLM

## Mesure et décision

- **Evals** vs benchmarks : SWE-bench Verified, « Leaderboard Illusion », loi de Goodhart
- **Coût complet par tâche réussie**
- La grille à cinq critères : licence · chemin de la donnée · qualité mesurée · sécurité du code *et* des actions · réversibilité

# A Données et paliers on-premise

## Taille des artefacts publiés

| MODÈLE | TOTAL / ACTIFS | ARTEFACT | CONFIGURATION |
|---|---|---|---|
| Qwen3.6-27B Apache-2.0 | 27 Md | FP8 30,9 Go | 1 × 48 Go |
| DeepSeek V4 Flash MIT | 284 / 13 Md | 160 Go | 2 × H200 |
| Qwen3.5-397B Apache-2.0 | 397 / 17 Md | FP4 ≈ 210 Go | 3 × H200 |
| GLM-5.2 MIT | 753 / ~40 Md | FP8 ≈ 750 Go | 8 × H200 |
| DeepSeek V4 Pro MIT | 1 600 / 49 Md | 865 Go | 8 × H200 |
| Kimi K3 clause MaaS | 2 800 / 104 Md | ≈ 1,5 To | multi-nœud |

Relevés Hugging Face, 16 septembre 2026. KV cache : Qwen3.6-27B ≈ 6,1 Gio pour 100 k tokens.

## Paliers de prix indicatifs

| | |
|---|---|
| 27B mono-GPU | 5 – 40 k€ |
| DeepSeek V4 Flash 2 × H200 | 60 – 120 k€ |
| Qwen 397B | 90 – 180 k€ |
| GLM-5.2 FP4 | 150 – 250 k€ |
| GLM-5.2 FP8 / V4 Pro | 300 – 450 k€ |

Neuf, hors installation, à confirmer par devis. ×2,5 à 3 si des salles sont à créer : « le matériel brut ne représente que 30 à 40 % de l'investissement réel ».

## Le coût réel du token possédé

8 × H200, ≈ 190 k€/an tout compris. À 5 000 tokens/s : **1,22 €/M tokens** à 100 % d'utilisation, 2,44 € à 50 %, 8,14 € à 15 %.

En dessous de 30 % d'utilisation, l'on-premise ne se justifie que par la sensibilité et la continuité — pas par le prix.

# A Offres cloud et éditeurs européens — version complète

| ACTEUR | CE QUI EST ÉTABLI | RÉSERVE |
|---|---|---|
| **Outscale**, **Cloud Temple** | LLMaaS sur infrastructure SecNumCloud | Statut du service LLM lui-même non établi |
| **S3NS** Thales + Google | SecNumCloud obtenu le 17 décembre 2025 | Model Garden open source seulement — **Gemini exclu** |
| **Bleu** Orange + Capgemini + Microsoft | Qualification en cours | — |
| **Hetzner, Exoscale, Aruba, T-Systems** | GPU bare-metal | Pas d'API LLM |
| **AWS European Sovereign Cloud** Brandebourg, janv. 2026 | Souveraineté **opérationnelle** réelle : personnel européen, clés que vous tenez | Juridiquement, la maison mère reste américaine |
| **Microsoft Data Guardian** | Même logique | Même réserve |
| **Mistral La Plateforme** | Hébergement UE par défaut ; seul éditeur frontier européen | Entraînement sur les données **par défaut** sauf opt-out ; ZDR « at our discretion » ; infrastructure sous-jacente non documentée |

**Rappel ANSSI — une offre hébergée sur une offre SecNumCloud n'est pas automatiquement qualifiée.**

En septembre 2026 : aucune API LLM managée n'est SecNumCloud, et aucun modèle fermé frontier n'est disponible dans une offre qualifiée.

# A Sources

**Le dossier complet, avec les dates de consultation, est dans le panneau documentaire — touche D.**

### Tableau 1 · La chaîne de valeur

TrendForce · SEMI · Counterpoint · Synergy Research · IEA · Stanford AI Index · CSIS · EPRS · Pillsbury · ASML AR 2025 · Cour des comptes européenne · Morgan Stanley · DIGITIMES · TechCrunch

### Tableau 2 · Le matériel

Nvidia (fév. et août 2026) · AMD IR · SemiAnalysis (avr. 2025, oct. 2025, fév. 2026) · The Next Platform · ServeTheHome · Phoronix · AMD ROCm blog · Tom's Hardware · IDC · Jon Peddie Research · Cerebras

### Tableau 3 · Le cloud et le TEE

Synergy Research · Sénat, commission d'enquête sur la commande publique · Nvidia developer blog · arXiv 2608.26575 · tee.fail · The Hacker News · Trail of Bits · Google Cloud blog · Apple Security · VentureBeat · Edgeless Systems · Scaleway · OVHcloud · Mistral · Futurum · InfoQ

### Tableaux 4 et 5 · Le harness et la personne

LiteLLM · CNIL · GLiNER (arXiv 2311.08526) · Microsoft Presidio · NIST SP 800-38G · 18 U.S.C. § 2713 · ANSSI SecNumCloud · Microsoft Learn (NPU) · AGENTS.md · CommonMark · « The Leaderboard Illusion » (arXiv 2504.20879) · SWE-bench Verified · OpenAI (retrait de GPT-4o) · tarifs publics Anthropic et Cursor · fiches de modèles Hugging Face, relevés des 8 et 16 septembre 2026

Chaque chiffre affiché dans ce support porte **sa date et sa source publique**, consultable dans le dossier documentaire. Le signe ⚠ ne marque pas une source manquante mais une **fourchette, un ordre de grandeur déduit ou une source secondaire unique**.